



University of Tehran

School of Electrical and Computer Engineering



---

# MACHINE LEARNING

---

## Assignment 2

Sasan Keshavarz  
810199253

Spring 2022

## فهرست

سوال ۱	.....	۳
سوال ۲	.....	۵
سوال ۳	.....	<b>Error! Bookmark not defined.</b>
سوال ۴	.....	۹
سوال ۵	.....	۹
سوال ۶	.....	۱۲

$$p(x) \sim N(\mu, \sigma^2) \quad \varphi(x) \sim N(0, 1) \rightarrow \varphi(x) = \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{x^2}{2}\right) \quad -1$$

$$p_n(x) = \frac{1}{nh_n} \sum_{i=1}^n \varphi\left(\frac{x-x_i}{h_n}\right)$$

$$\tilde{p}_n(x) = E(p_n(x)) = \frac{1}{nh_n} \sum_{i=1}^n E\left(\varphi\left(\frac{x-x_i}{h_n}\right)\right) = \frac{1}{h_n} \int_{-\infty}^{\infty} \varphi\left(\frac{x-u}{h_n}\right) p(u) du \quad (\text{انت})$$

$$\tilde{p}_n(x) = \frac{1}{h_n} \int_{-\infty}^{\infty} \frac{1}{\sqrt{2\pi}} \exp\left(-\frac{1}{2} \left(\frac{x-u}{h_n}\right)^2\right) \frac{1}{\sqrt{2\pi}\sigma} \exp\left(-\frac{1}{2} \left(\frac{u-\mu}{\sigma}\right)^2\right) du$$

$$= \frac{1}{\sqrt{2\pi} h_n \sigma} \exp\left(-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2}\right)\right) \int_{-\infty}^{\infty} \exp\left(-\frac{1}{2} \left(\frac{u^2}{h_n^2} + \frac{u^2}{\sigma^2}\right) - 2\frac{u}{h_n} \left(\frac{x}{h_n} + \frac{\mu}{\sigma}\right)\right) du$$

$$= \frac{1}{\sqrt{2\pi} h_n \sigma} \exp\left(-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2}\right) + \frac{1}{2} \frac{k^2}{\theta^2}\right) \int_{-\infty}^{\infty} \exp\left(-\frac{1}{2} \left(\frac{u-k}{\theta}\right)^2\right) du$$

$$\theta = \frac{h_n^2 \sigma^2}{h_n^2 + \sigma^2}, \quad k = \theta \left(\frac{x}{h_n^2} + \frac{\mu}{\sigma^2}\right)$$

$$\tilde{p}_n(x) = \frac{\sqrt{2\pi} \theta}{\sqrt{2\pi} h_n \sigma} \exp\left(-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2}\right) + \frac{1}{2} \frac{k^2}{\theta^2}\right)$$

$$= \frac{h_n \sigma}{\sqrt{2\pi} h_n \sigma \sqrt{h_n^2 + \sigma^2}} \exp\left(-\frac{1}{2} \left(\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} + \frac{k^2}{\theta^2}\right)\right)$$

$$\frac{x^2}{h_n^2} + \frac{\mu^2}{\sigma^2} + \frac{k^2}{\theta^2} = \frac{x^2 h_n^2}{(h_n^2 + \sigma^2) h_n^2} + \frac{\mu^2 \sigma^2}{(h_n^2 + \sigma^2) \sigma^2} - \frac{2x\mu}{h_n^2 + \sigma^2} = \frac{(x-\mu)^2}{h_n^2 + \sigma^2}$$

$$\rightarrow \tilde{p}_n(x) = \frac{1}{\sqrt{2\pi} \sqrt{h_n^2 + \sigma^2}} \exp\left(-\frac{1}{2} \frac{(x-\mu)^2}{h_n^2 + \sigma^2}\right) \rightarrow \tilde{p}_n(x) \sim N(\mu, h_n^2 + \sigma^2)$$

$$\begin{aligned}
 P_n(x) - \tilde{P}_n(x) &= \frac{1}{\sqrt{\pi}6} \exp\left(-\frac{1}{\pi} \frac{(x-\mu)^r}{6^r}\right) - \frac{1}{\sqrt{\pi} \sqrt{h_n^r + 6^r}} \exp\left(-\frac{1}{\pi} \frac{(x-\mu)^r}{h_n^r + 6^r}\right) \quad (\rightarrow -1) \\
 &= \frac{1}{\sqrt{\pi}6} \exp\left(-\frac{1}{\pi} \frac{(x-\mu)^r}{h_n^r + 6^r}\right) \left(1 - \frac{6}{\sqrt{h_n^r + 6^r}} \exp\left(-\frac{1}{\pi} \frac{(x-\mu)^r}{h_n^r + 6^r}\right) + \frac{1}{\pi} \frac{(x-\mu)^r}{6^r}\right) \\
 &= P(x) \left(1 - \frac{1}{\sqrt{1 + (h_n/6)^r}} \exp\left(-\frac{(x-\mu)^r}{\pi} \left(\frac{1}{h_n^r + 6^r} - \frac{1}{6^r}\right)\right)\right) \\
 &= P(x) \left(1 - \frac{1}{(1 + (h_n/6)^r)^{1/r}} \exp\left(\frac{1}{\pi} \frac{h_n^r (x-\mu)^r}{h_n^r + 6^r}\right)\right) \xrightarrow{h_n \rightarrow 0} \frac{1}{\sqrt{1 + (h_n/6)^r}} \approx 1 - \frac{1}{\pi} (h_n/6)^r
 \end{aligned}$$

$$\lim_{h_n \rightarrow 0} \exp\left(\frac{h_n^r (x-\mu)^r}{\pi 6^r}\right) \approx 1 + \frac{h_n^r}{\pi 6^r} \frac{(x-\mu)^r}{h_n^r + 6^r}$$

$$\begin{aligned}
 P(x) - \tilde{P}_n(x) &= P(x) \left(1 - \left(1 - \frac{1}{\pi} \left(\frac{h_n}{6}\right)^r\right) \left(1 + \frac{h_n^r}{\pi 6^r} \frac{(x-\mu)^r}{h_n^r + 6^r}\right)\right) \xrightarrow{h_n \rightarrow 0} \frac{h_n^r}{\pi 6^r} \frac{(x-\mu)^r}{h_n^r + 6^r} \\
 &= P(x) \left(1 - 1 + \frac{h_n^r}{\pi 6^r} - \frac{h_n^r}{\pi 6^r} \frac{(x-\mu)^r}{h_n^r + 6^r}\right) = P(x) \left(\frac{1}{\pi} \left(\frac{h_n}{6}\right)^r \left(1 - \frac{(x-\mu)^r}{h_n^r + 6^r}\right)\right)
 \end{aligned}$$

$$\rightarrow P(x) - \tilde{P}_n(x) \approx \frac{1}{\pi} \left(\frac{h_n}{6}\right)^r \left(1 - \frac{(x-\mu)^r}{6^r}\right) P(x)$$

$$\begin{aligned}
 \text{Var}(P_n(x)) &= \text{Var}\left(\frac{1}{nh_n} \sum_{i=1}^n \varphi\left(\frac{x-x_i}{h_n}\right)\right) \stackrel{X_i \rightarrow i.i.d}{=} \frac{1}{nh_n^r} \sum_{i=1}^n \text{Var}\left(\frac{\varphi(x-x_i)}{h_n}\right) \quad (\text{C} - 1) \\
 \text{Var}(P_n(x)) &= \frac{1}{nh_n^r} \text{Var}\left(\varphi\left(\frac{x-a}{h_n}\right)\right) = \frac{1}{nh_n^r} \left(\underbrace{E\left(\varphi^r\left(\frac{x-a}{h_n}\right)\right)}_{\text{I}} - \underbrace{E\left(\varphi\left(\frac{x-a}{h_n}\right)\right)^2}_{\text{II}}\right)
 \end{aligned}$$

$$\begin{aligned}
 \text{I} : E\left(\varphi^r\left(\frac{x-a}{h_n}\right)\right) &= \int_{-\infty}^{\infty} \varphi^r\left(\frac{x-a}{h_n}\right) P(u) du = \\
 &= \int_{-\infty}^{\infty} \frac{1}{\sqrt{\pi}} \exp\left(-\frac{(x-u)^r}{h_n^r}\right) \underbrace{\frac{1}{\sqrt{\pi}6}}_{\text{I}} \exp\left(-\frac{1}{\pi} \frac{(u-\mu)^r}{6^r}\right) du
 \end{aligned}$$

در اینجا،  $\mu = 0$

$$\begin{aligned}
 E\left(\varphi^r\left(\frac{x-u}{h_n}\right)\right) &= \frac{1}{\sqrt{r\pi}} \int_{-\infty}^{\infty} \frac{1}{\sqrt{r\pi}} \exp\left(-\frac{1}{r}\left(\frac{x-u}{h_n}\right)^r\right) \exp\left(-\frac{1}{r}\left(\frac{u-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right) \frac{1}{\sqrt{r\pi}} \exp\left(-\frac{1}{r}\left(\frac{u-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right) du \\
 &= \frac{1}{\left(\frac{h_n}{\sqrt{r}}\right)} \int_{-\infty}^{\infty} \frac{1}{\sqrt{r\pi}} \exp\left(-\frac{1}{r}\left(\frac{x-u}{h_n}\right)^r\right) \frac{1}{\sqrt{r\pi}} \exp\left(-\frac{1}{r}\left(\frac{u-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right) du \\
 &= \frac{1}{\sqrt{r\pi} \frac{h_n^r}{r} + 6^r} \exp\left(-\frac{1}{r}\left(\frac{x-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right) = \frac{\frac{h_n}{\sqrt{r}}}{r\pi \sqrt{\frac{h_n^r}{r} + 6^r}} \exp\left(-\frac{1}{r}\left(\frac{x-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right) \\
 \frac{1}{nh_n^r} E\left(\varphi^r\left(\frac{x-u}{h_n}\right)\right) &= \frac{1}{nh_n^r \sqrt{r\pi} \sqrt{\frac{h_n^r}{r} + 6^r}} \exp\left(-\frac{1}{r}\left(\frac{x-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right) \\
 \lim_{h_n \rightarrow 0} \sqrt{\frac{h_n^r}{r} + 6^r} &= 6 \Rightarrow \frac{1}{nh_n^r} E\left(\varphi^r\left(\frac{x-u}{h_n}\right)\right) = \frac{1}{r\pi} \underbrace{\frac{1}{\sqrt{r\pi} 6}}_{p(x)} \exp\left(-\frac{1}{r}\left(\frac{x-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right)
 \end{aligned}$$

$$\textcircled{\text{ii}} \quad E^r\left(\varphi\left(\frac{x-u}{h_n}\right)\right) = \frac{h_n^r}{\sqrt{r\pi} \sqrt{h_n^r + 6^r}} \exp\left(-\frac{1}{r}\left(\frac{x-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right)$$

$$\Rightarrow \frac{1}{nh_n^r} E^r\left(\varphi\left(\frac{x-u}{h_n}\right)\right) \approx \frac{h_n}{nh_n} \frac{1}{\sqrt{r\pi} 6} \exp\left(-\frac{1}{r}\left(\frac{x-\mu}{\frac{h_n}{\sqrt{r}}}\right)^r\right) = 0$$

$$\rightarrow \text{var}[p_n(x)] = \frac{1}{nh_n^r} E\left(\varphi^r\left(\frac{x-u}{h_n}\right)\right) \approx \frac{1}{r\pi nh_n \sqrt{r\pi}} p(x)$$

2- باینه بی کیم که آیا خاصه شریک  $D(a,b) = \sqrt{\sum_{k=1}^d (a_k - b_k)^2}$  هچنار برقراره کانه.

$$x_k^* = \alpha_k x_k$$

Ⓐ خاصیت اول شریک اینست که نامنفی باشه جرد هچنار از  $\sum_{k=1}^d x_k^2$  بصورت تعدادی مربعات جلالت ساخته شده بر هچنار نامنفی باقی مانه.



ادامه سوال 2:  $D(a, b) = \sqrt{\sum_{k=1}^d \alpha_k^2 (a_k - b_k)^2}$

B - خاصیت بازتاب را بپذیریم که اگر  $D(a, b)$  برابر صفر باشد باید  $a = b$  باشد.  
از رابطه  $D(a, b)$  واضح است که زمانی صفر شده که  $a = b$  باشد.  
همچنین زمانی که  $a = b$  باشد  $D(a, b) = 0$  خواهد شد.

C - باید خاصیت تقارن را بررسی کنیم که  $D(a, b) \stackrel{?}{=} D(b, a)$ .

$(a_k - b_k)^2 = (b_k - a_k)^2$   
$$\sqrt{\sum_{k=1}^d \alpha_k^2 (a_k - b_k)^2} = \sqrt{\sum_{k=1}^d \alpha_k^2 (b_k - a_k)^2}$$

D - ما باید ناسازی سلت را بررسی کنیم:  
 $D(a, b) + D(b, c) \geq D(a, c)$

که  $A$  یک ماتریس قطری از ضرایب  $\alpha_k$  است.  $D^2(a, b) = \|A(a-b)\|_2$

$\|A(a-c)\|_2 + \|A(c-b)\|_2 \geq \|A(a-b)\|_2 \rightarrow \begin{cases} a-b = (a-c) \\ \quad \quad \quad + (c-b) \end{cases}$   
به دنبال اثبات این هستیم.

$A(a-c)$  را  $x$  در نظر بگیریم و  $A(c-b)$  را  $y$  و رابطه را باز نویسی کنیم.

مرد و ملزم به توان 2 داریم  $\rightarrow \|x\|_2 + \|y\|_2 \geq \|x+y\|_2$   
$$\|x\|_2 + \|y\|_2 \geq \|x+y\|_2 \rightarrow \|x\|_2^2 + \|y\|_2^2 + 2\|x\|_2\|y\|_2 \geq \|x\|_2^2 + \|y\|_2^2 + 2\sum_{i=1}^d x_i y_i$$
  
$$(\|x\|_2 + \|y\|_2)^2 \geq \|x\|_2^2 + \|y\|_2^2 + 2\|x\|_2\|y\|_2$$
  
این همان ناسازی کوشی-شوارتز است و بدین شکل  $\sum_{i=1}^d x_i y_i \leq \|x\|_2 \|y\|_2$   
پس خاصیت ناسازی سلت هم اثبات شده.

بدون این متدیک همه عناصر متدیک استاندارد را دارد پس بتوان از آن برای  $knn$  استفاده کرد.  
بدون به هر حال  $k$  عدد از ناصله ها کمتر از بقیه نواصل هستند و بتوان به اکثر تعداد کلاسهای نزدیک به یک داده جدید را به عنوان کلاس داده جدید در نظر گرفت.

ادامه سؤال 2 :

باقی به اینکه منب  $\alpha \times$  را در ابعاد منب یکیم و قرانیم با در نظر گرفتن  $\alpha = 0$  برای بعضی ابعاد آن ها را حذف کنیم و روش پیش ساختار بندی و پیرایش را انجام دهیم. همچنین مقدار عملیات حیاتی feature scaling را برای ابعاد مختلف انجام داد تا  $knn$  نتیجه شگفتی دست دهد.

(3) فرض می کنیم دسته اول مرکزش در 0 است و دسته دوم مرکزش در 1 است

$$P(w_1) = P(w_2) = \frac{1}{2}$$

$$P(w_1 | x) = \begin{cases} 1 & \|x\| \leq 1 \\ 0 & \text{و.ع} \end{cases}$$

$$P(w_2 | x) = \begin{cases} 1 & \|x - 1\| \leq 1 \\ 0 & \text{و.ع} \end{cases}$$

الف)  $P_Q(e)$  متوسط احتمال خطا به ازای  $Q$  نقطه است.

$$P_Q(e) = P(x \in w_1 | w_2) + P(x \in w_2 | w_1) \xrightarrow{\text{نقطه در خط}}$$

$$P_Q(e) = 2P(x \in w_1 | w_2) = 2P(w_1) P\left(\frac{(K-1)}{2}\right)$$

برای  $w_1$  برای کته از  $\frac{(K-1)}{2}$  نقطه باشد و به  $w_2$  بقیه  $w_1$  است

$$P_Q(e) = (2) \left(\frac{1}{2}\right) \sum_{j=0}^{K-1} P_0(\text{نقطه } Q \text{ به } w_1 \text{ برود})$$

ضروری اند.

$$P_Q(e) = \sum_{j=0}^{K-1} \binom{Q}{j} \frac{1}{2^j} \frac{1}{2^{Q-j}} = \frac{1}{2^Q} \sum_{j=0}^{(K-1)} \binom{Q}{j}$$

ب)  $P_Q(e_{0K})$  وابسته به  $Q$  و  $K$  هستند. متوسط احتمال خطا به ازای  $Q$  و  $K$  هستند.

$$P_Q(e_{01}) = \frac{1}{2^Q} < P_Q(e_{0K}) = \frac{1}{2^Q} \sum_{j=0}^{(K-1)} \binom{Q}{j} \quad (K > 1)$$

$$\lim_{Q \rightarrow \infty} P_Q(e) = 0$$

(C)

$$P_Q(e) = \frac{1}{r^Q} \sum_{j=0}^{\left(\frac{Q-1}{r}\right)} \binom{Q}{j} = P(B(n, \frac{1}{r}) \leq \frac{Q-1}{r})$$

$$= P(Y_1 + \dots + Y_n \leq \frac{Q-1}{r})$$

که  $Y_i$  ها iid باشند  $P(Y_i=1) = P(Y_i=0) = \frac{1}{r}$   $\Rightarrow$  B یک توزیع دوجمله‌ای

$$P_Q(e) \leq P(Y_1 + \dots + Y_n \leq \frac{Q}{rn} - 1) \xrightarrow{n \rightarrow \infty} P(Y_1, \dots, Y_n \leq 0) = 0$$

$$\rightarrow P_Q(e) = 0$$

$$Q \rightarrow \infty$$



## سوال ۴

### بخش اول

#### مفهوم مصالحه بایاس واریانس در knn و پارزن

در روش پارزن پارامتر  $hn$  نقش اساسی دارد. هرچه قدر بزرگتر باشد مدل ساده تر خواهد بود و خطای بایاس بیشتر میشود و به نفع واریانس مصالحه انجام شده است. هرچه قدر طول پنجره پارزن کوچکتر باشد مدل دقیقتر است و نویز داده هم ممکن است مدل شود و خطای واریانس بیشتر خواهد شد.

در روش knn هایپرپارامتر  $k$  است. هرچه قدر  $k$  که نشان دهنده تعداد داده موجود در هر حجم مورد نظر است میباشد کوچکتر باشد مدل اسپایکی تر خواهد شد و هرچه قدر این تعداد همسایگی  $k$  بزرگتر بشود مدل نرم تر میشود. پس  $k$  کوچک خطای واریانس را زیاد میکند و مدل پیچیده تر میشود و  $k$  بزرگ خطای بایاس را زیاد میکند و مدل ساده تر میشود.

#### تفاوت روشهای پارامتری و غیرپارامتری

در روشهای پارامتری ما یک توزیع اولیه برای داده در نظر میگیریم و به روشهای مختلف به دنبال آن هستیم که پارامترهای این توزیع مفروض را تخمین بزنیم. اما در روشهای غیرپارامتری هیچ مدل اولیه ای برای داده فرض نمیشود و از خود توزیع داده ها برای تخمین نوع توزیع استفاده میشود. در واقع بر اساس همسایگی و هیستوگرام، توزیع داده ها را تخمین میزنیم. مزیت روش پارامتریک این است که حسابات بسیار سبک تر هستند و اگر از روش بیزی استفاده شود میتوان هر بار نسبت به یک دیتاست جدید پارامتر توزیع را آپدیت کرد و بسیار خوش تعریف هستند. اما ایراد آن این است که همیشه توزیع داده ها مطابق توزیع مفروض ما نیست و میتواند تفاوت بسیار زیادی با آن داشته باشد. مزیت روشهای غیرپارامتری این است که مدل غیرواقعی برای توزیع فرض نمیکند اما ایراد آن این است که همیشه به کل داده برای تخمین توزیع داده ها نیاز داریم و حجم محاسبات آن بسیار سنگین است.

#### مشکل روشهای بر اساس کرنل


مشکل اصلی این است که اساسا تشخیص بهترین کرنل دشوار است و نمیتوان بهترین کرنل ممکن را در نظر گرفت. همچنین هنگامی که داده ها sparse باشند و در نواحی که داده های کمی وجود دارند این روش ها خوب عمل نمیکند.

#### تفاوت مفهوم حجم در روش پارزن و knn


در روش پارزن حجم را برای یک تعداد مشخص داده ثابت فرض میکنیم و برای تخمین احتمال محاسبه میکنیم چه تعداد داده در هر حجم مفروض قرار گرفته است. این حجم با افزایش تعداد کل داده ها کوچکتر میشود. در روش knn ما تعداد داده که باید در یک حجم قرار بگیرد را برای یک تعداد مشخص ثابت فرض میکنیم و در اطراف داده جدید انقدر حجم را بزرگ میکنیم که تعداد  $k$  داده در آن حجم قرار بگیرد. سپس احتمال از فرمول  $k/nv$  محاسبه میشود. در این روش با افزایش تعداد کل داده  $k$  با سرعت کمتری افزایش پیدا میکند.

## بخش دوم


به سادگی یک آرایه ۱۰۰۰ در ۵ تولید میکنیم و سپس برای محاسبه فواصل از دو حلقه تو در تو استفاده میکنیم. نتایج برای داده های ۵ بعدی و مقدار داده ۱۰۰۰، ۲۰۰۰، ۵۰۰۰ و ۱۰۰۰۰ در زیر رسم شده است.



$N=1000, d=5$



$N=2000, d=5$



$N=5000, d=5$

برای طولانی شدن کد هر بار مقدار  $n$  را تغییر دادم و دیگر برای هر  $n$  یک سلول در نظر نگرفتم.

## (ب)

سپس برای بررسی تاثیر افزایش ابعاد یک سری داده رندوم جدید به ابعاد ۱۰۰ در نظر گرفتم و این بار هم هر دفعه  $n$  را اپدیت کردم و هیستوگرامها ترسیم گردد.

متأسفانه به علت کندی بسیار در ران کردن کد و اینکه همانطور که در سایت ایلرن مشاهده میفرمایید بنده در آخرین ساعات تمرین را اپلود کردم و زمان کافی برای اجرای کد نبود. کدها هیچ ایرادی ندارند و صرفاً به علت کمبود زمان نتوانستم نتیجه اجرای آنها را در گزارش بیاورم. لطفاً نمره ای کسر نکنید. متشکرم.


## (ج)

هرچقدر تعداد داده زیاد شد، هیستوگرام نرم تر میشود ولی به شدت نتیجه کندتر به دست می آید. در اثر افزایش ابعاد دچار نحسی ابعاد میشویم و تعداد داده مورد نیاز برای آموزش داده به صورت نمایی افزایش می یابد. خود افزایش ابعاد هم بسیار روند نتیجه گیری از کد را کند میکند. در روش knn که پیش پردازش داده ها در آن انجام ندشه باشد گاهی با تعداد خیلی زیادی داده سر و کار داریم و گاهی تعداد ابعاد این دادگان هم بسیار زیاد است. در این صورت الگوریتم knn بسیار زمان بر خواهد بود و هزینه محاسباتی زیادی خواهد داشت. در نتیجه اعمال روش های pre structuring برای knn ضروری به نظر میرسد.

## سوال ۵

قسمت پیاده سازی بدون کتابخانه را نتوانستم انجام دهم.

(ج) با استفاده از کتابخانه کرنل گاوسی را با پهنای باند ۱۰، ۲۰، ۵۰ و ۱۰۰ رسم کرده و در شکل زیر جواب نمایش داده شده است.



(ب)

همانطور که از نمودار مشخص است با افزایش پهنای باند نمودار تخمین زده شده برای توزیع نرم تر میشود.




## سوال ۶

ابتدا بخشی از داده را بعد از تست جدا میکنیم سپس در قسمت validation، نسبت را ۰,۱ در نظر میگیریم.

مدل را sequential در نظر میگیریم و چون ورودی ها تصویر ها ۲۸ در ۲۸ هستند آنها را flatten میکنیم. برای learning rate یک بردار ۵ تایی در نظر میگیریم و برای learning units هر لایه یک بردار ۳ تایی تعریف میکنیم. تابع activation را برای هر لایه relu در نظر گرفتیم و برای لایه آخر که قرار است یکی از ۱۰ کلاس را اختصاص دهد تابع softmax بهترین گزینه برای تابع فعال سازی بود. همچنین برای آموزش شبکه کل مدلهای epoch را ۱۰ در نظر میگیریم و batch\_size را ۱۶ تعیین میکنیم.

## الف)

نمودار دقت و خطا برای داده train و validation را برای پارامترهای نرخ یادگیری 0/001 و یک لایه پنهان و تعداد ۵۰ یونیت و sover را sgd در نظر میگیریم. نتیجه در زیر نمایش داده شده است.



برای داده های تست  $loss = 1.56$  و  $accuracy = 0.35$  به دست آمد.


## ب و ج)

با بررسی learning rate بهترین مقدار نرخ یادگیری 0.001 به دست آمد. بقیه مقادیر تفاوت چندانی با هم نداشتند و الگوی مشخصی وجود نداشت چون در حالات مختلف هر کدام یک طور عمل میکردند. هرچقدر تعداد لایه ها را افزایش دادم نتیجه بهتری گرفتم. برای بررسی این موضوع ابتدا لایه دوم و سوم را کامنت کردم و بهترین نتیجه با ۳ لایه پنهان به دست آمد.

در مورد اندازه یونیت‌های لایه مخفی بهترین مقدار برابر ۱۵۰ شد و هرچه قدر اندازه بزرگتر شد نتایج بهتری گرفتیم.

بهترین نتیجه میان solver ها را با ADAM گرفتیم. عملکرد sgd البته تفاوت زیادی با این نداشت اما اصلا نتایج خوبی با rpmprop حاصل نشد.

نتیجه استفاده از بهترین پارامترها در شکل زیر نمایش داده شده است.



برای داده های تست  $loss = 0.41$  و  $accuracy = 0.85$  به دست آمد.

## سوال ۷

در این سوال ابتدا نقاط را در فضا تعریف کردم و یک بردار برای برجسبها تعریف کردم. سپس با line coordinates دو خط تعریف کردم با وزنهای که در انتها از آموزش شبکه به دست آمدند.

تابع perceptron را تعریف کردم که در آن ورودی ها داده های آموزش، برجسبها، مقادیر اولیه رندوم وزن و بایاس و تعداد iteration هستند. خروجی آن وزنهای اصلاح شده، بایاس اصلاح شده و برجسبهای به دست آمده از شبکه جدید خواهد بود.

یک لایه آخر or برای ایجاد محیط مطلوب میان خطوط در نظر گرفته شد. سپس فرایند آموزش را مطابق آنچه در فایل کد مربوطه است انجام دادیم. رابطه مربوط به پرسپترون را برای دو نورون لایه اول برای ورودی ها به ترتیب محاسبه میشود اگر برجسب درست اطلاق شد که میرود ورودی بعدی. در غیر اینصورت اگر برجسب

۱ باشد، وزن و بایاس متناظر با کمترین zin را اپدیت میکند. و اگر برچسب ۱- باشد zin که مثبت را با تابع posefinder پیدا کرده و وزن مربوطه را اصلاح میکند. در انتها برچسب نهایی به داده اطلاق میشود. یعنی برچسبی که غلط بوده را اصلاح میکنیم.

معادله خطوط اولیه جدا کننده پس از آموزش شبکه بعد از اصلاح ماتریس وزنها و بایاس به دست می آید و نتیجه در شکل زیر نمایش داده شده است.

